



Önálló laboratórium beszámoló

Távközlési és Mesterséges Intelligencia Tanszék

Készítette:	Németh Máté
Neptun-kód:	E3YAXE
Szakirány:	Mérnökinformatikus BSc
E-mail cím:	nemmatee2004@gmail.com
Konzulens(ek):	Frankó Attila
E-mail címe(ik):	franko@tmit.bme.hu

Téma címe: Labdarúgó mérkőzések prediktív modellezése és sportanalitikai elemzése

Feladat

A feladatom célja az Angol Premier League mérkőzéseinek sportanalitikai elemzése és prediktív modellezése volt. A félév során a football-data.co.uk nyilvános adatbázisából a 2015/16-os szezontól kezdődően letöltöttem, integráltam és tisztítottam a Premier League mérkőzésadatait. Ezt követően felderítő adatelemzést (EDA) végeztem, feltártam a mérkőzések kimenetelét befolyásoló statisztikai tényezőket, és validáltam az előzetesen felállított hipotéziseket. Az adatelemzés eredményeire támaszkodva származtatott jellemzőket (feature engineering) alakítottam ki, mint például a csapatok aktuális formájának mérőszámait. Végül célom volt egy olyan gépi tanulási modell megtervezése, implementálása és optimalizálása, amely a historikus adatok és a származtatott jellemzők alapján képes prediktálni a mérkőzések végeredményét (Hazai győzelem, Döntetlen, Vendég győzelem).

2025/2026. 2. félév

Tartalom

.....	1
Önálló laboratórium beszámoló	1
Téma címe: Labdarúgó mérkőzések prediktív modellezése és sportanalitikai elemzése	1
Feladat	1
1. Munkakörnyezet, előzmények és kiindulási állapot	2
1.1 Bevezető	2
1.2 Elméleti összefoglaló	2
1.3 A munka állapota, készségi foka a félév elején.....	2
2. Az elvégzett munka és eredmények ismertetése	3
2.1 Adatgyűjtés, -integráció és -tisztítás.....	3
2.2 Feltáró Adatelemzés (EDA)	4
2.3 Hipotézisvizsgálatok	4
2.3.1 A COVID-19 hatása a hazai pálya előnyére (H1)	4
2.3.2 A lövések minőségének és mennyiségének prediktív értéke (H2)	5
2.3.3 A fogadóirodai oddsok prediktív ereje (H3).....	5
2.4 Jellemzőkinyerés (Feature Engineering).....	5
2.5 Új Összefüggések Felfedezése és Új Hipotézisek.....	6
2.5.1 H4 Hipotézis: A piros lap aszimmetrikus hatása	7
2.5.2 H5 Hipotézis: A Form_Diff prediktív ereje.....	7
2.6 Prediktív Modellezés és Hipotézisek Validálása Modellekkel.....	7
2.6.1 Modell a H1 hipotézisre (COVID hatása).....	7
2.6.2 Modell a H2 hipotézisre (Lövések prediktív értéke).....	7
2.6.3 Modell a H3 hipotézisre (Oddsok prediktív ereje).....	7
2.6.4 Modell a H4 hipotézisre (Piros lapok aszimmetrikus hatása)	8
2.6.5 Modell a H5 hipotézisre (Form_Diff prediktív ereje)	8
2.6.6 A végső, hibrid modell kialakítása és optimalizálása	8
2.7 Összefoglalás.....	10
3. Irodalom, és csatlakozó dokumentumok jegyzéke.....	11
A tanulmányozott irodalom jegyzéke:.....	11
Csatlakozó egyéb elkészült dokumentációk / fájlok / stb. jegyzéke:	11

1. Munkakörnyezet, előzmények és kiindulási állapot

1.1 Bevezető

A modern labdarúgásban az adatalapú döntéshozatal mára megkerülhetetlenné vált mind a professzionális klubok, mind a fogadóirodák számára. Egy mérkőzés kimenetele látszólag a véletlen is múlhat, de a rögzített nagyszámú statisztikai adatban (pl. lövések, szögletek, szabálytalanságok) olyan összefüggések rejtőznek, amelyek feltárása lehetővé teszi a teljesítmény objektív elemzését és előrejelzését [1]. A sportanalitika területén a gépi tanulási modellek alkalmazása rohamosan fejlődött, és számos kutatás igazolta, hogy a megfelelő jellemzők és osztályozó algoritmusok felülmúlhatják a hagyományos előrejelzéseket.

1.2 Elméleti összefoglaló

A kutatás a football-data.co.uk [5] nyilvános adatbázisára épül, amely historikus mérkőzésadatokat, alapstatisztikákat (lövések, szögletek, lapok) és vezető fogadóirodák nyitó szorzóit is tartalmazza, lehetővé téve a piaci és a statisztikai modellek közvetlen összehasonlítását.

A nemzetközi szakirodalomban több szerző foglalkozott hasonló problémákkal. Baboota és Kaur [2] négy európai topliga adatait felhasználva hasonlítottak össze gépi tanulási modelleket (többek között Random Forest és Support Vector Machine) a mérkőzések kimenetelének predikciójára. Munkájukban a feature engineering fontosságát hangsúlyozták, kiemelve, hogy a származtatott jellemzők (pl. a csapatok formája) jelentősen javítják a predikció pontosságát. Hasonló megközelítést alkalmazott Tax és Joulstra [4], akik a holland bajnokság adataira építettek prediktív modellt, és kimutatták, hogy a múltbeli teljesítményből származtatott jellemzők bevonása szignifikánsan növeli a modell prediktív képességét.

A fogadóirodai oddsok prediktív ereje ugyancsak visszatérő kutatási téma. Constantinou és Fenton [3] egy Bayes-hálós modellt fejlesztettek, amely az oddsokból és egyéb mérkőzésstatisztikákból kiindulva becsülte a kimenetel valószínűségét. Eredményeik azt mutatták, hogy a piaci oddsok erős prediktorok, de kiegészítő statisztikai jellemzőkkel kombinálva javítható a modell teljesítménye. Jelen munka célja hasonló: egy gépi tanuláson alapuló keretrendszer kialakítása, amely a múltbeli mérkőzések adataiból, a piaci információkból és a saját fejlesztésű jellemzőkből együttesen becslést ad a mérkőzés kimenetelére (Hazai győzelem, Döntetlen, Vendég győzelem).

A megvalósítás Python nyelven történt, a következő könyvtárakkal: Pandas, NumPy adatkezeléshez és számításokhoz; Matplotlib, Seaborn, Plotly vizualizációhoz; Scikit-learn [6] a gépi tanuláshoz; Optuna [7] a hiperparaméter-optimalizáláshoz.

1.3 A munka állapota, készültségi foka a félév elején

A félév kezdetén kizárólag az általam kezdeményezett, konzulensemmel egyeztetett feladatkiírás és az ennek alapján készült munkaterv állt rendelkezésre; a feladat nyilvános labdarúgó-adatbázis elemzését és prediktív modellezését írta elő, ám sem konkrét adatforrás, sem előre letöltött/tisztított adatbázis nem volt megadva. A szükséges gépi tanulási ismeretekkel (felügyelt tanulás, osztályozási és regressziós modellek, kiértékelési metrikák) már rendelkeztem korábbi tanulmányaimból, a sportanalitika és a mérkőzések statisztikai elemzése azonban új terület volt számomra, így a félév során a hangsúly a meglévő tudás alkalmazására, a feature engineering kialakítására és a modell optimalizálására helyeződött. A kiválasztott adatforrás a Premier League 2015/16 utáni szezonjait szezononkénti CSV-kben tartalmazta; az oszlopstruktúra évente változott, ami integrációs nehézséget okozott.

2. Az elvégzett munka és eredmények ismertetése

A félév során végzett munkám egy komplex, több lépésből álló adatelemzési és modellezési folyamat volt, amely a nyers adatok letöltésétől egészen egy optimalizált prediktív modell elkészítéséig terjedt. A következő alfejezetekben ezt a folyamatot mutatom be, a notebookom (`foci_onlab.ipynb`) szerkezetét követve: az adatok előkészítésétől és a kezdeti vizualizációktól kezdve, a hipotézisek tesztelésén és a feature engineering fázison át, egészen a prediktív modellek implementálásáig és a végső konklúziók levonásáig.

2.1 Adatgyűjtés, -integráció és -tisztítás

A munka első fázisa egy automatizált adatgyűjtő pipeline kiépítése volt. Ennek keretében egy Python szkript segítségével a football-data.co.uk [5] weboldalról programozottan letöltöttem az angol Premier League (E0) 2015/16-os és 2024/25-ös szezonjai közötti összes, összesen 10 szezonális CSV fájlt. A letöltő kód úgy lett megtervezve, hogy a már korábban letöltött, helyben meglévő fájlokat ne töltsse le újra, ezzel elkerülve a felesleges hálózati forgalmat és a szerver szükségtelen terhelését.

A különálló szezonfájlok oszlopstruktúrája az évek során kismértékben eltért: egyes fogadóirodák megszűntek, újabbak jelentek meg az adatbázisban. Az egységesítés érdekében a betöltés során minden rekordot elláttam egy Season azonosítóval, amely a fájlnevből kinyert évszámok alapján került meghatározásra. Ezt követően az összes szezon adatait egyetlen Pandas DataFrame-be egyesítettem, amely így összesen **3800** mérkőzést és **155** statisztikai változót tartalmazott.

Az adatok minőségének biztosítása és a modellépítés előkészítése érdekében a következő tisztítási lépéseket hajtottam végre:

- **Duplikátumok ellenőrzése:** A `deduplicated()` metódus nem talált ismétlődő sort, így szűrésre nem volt szükség
- **Hiányzó értékek feltérképezése:** Az `isnull()` metódussal feltártam, hogy 155 oszlopból közel 120-ban >90%-os hiány mutatkozik, főként megszűnt fogadóirodákánál. Ezek irrelevánsak voltak.
- **Releváns változók kiválasztása:** Az adathalmazt leszűkítettem egy **26** releváns, közel 100%-ban kitöltött oszlopból álló halmazra. Az elnevezésekben a 'H' (Home) a hazai, az 'A' (Away) a vendégcsapatot jelöli. A megtartott változók: alapadatok (`Date`, `HomeTeam`, `AwayTeam`, `Referee`), végeredmények (`FTHG`, `FTAG`, `FTR`, stb.)¹, mérkőzésstatisztikák (`HS`, `AS`, `HST`, `AST` – lövések; `HC`, `AC` – szögletek; `HF`, `AF` – szabálytalanságok; `HY`, `AY` – sárga, `HR`, `AR` – piros lapok), valamint a fogadóirodai oddsok (`B365H`, `B365D`, `B365A`). A `dropna()` alkalmazása után nem maradt hiányzó adat.
- **Dátum-formázás:** A `Date` oszlopot a `pd.to_datetime()` függvénnyel szabványos datetime típusúvá konvertáltam, a `dayfirst=True` paraméterrel kezelve az európai dátumformátumot. Ez a lépés elengedhetetlen volt az időalapú elemzésekhez, a szezonok szétválasztásához és különösen a későbbi feature engineering fázishoz, ahol a mérkőzés dátumát használtam a múltbeli teljesítmények szűrésére.
- **Sorbarendezés:** Az adathalmazt a `Date` oszlop szerint időrendbe rendeztem a `sort_values()` metódussal, ami a későbbi iteratív forma-számítások helyességéhez

¹ A football-data.co.uk standard angol rövidítései: FT = Full Time (végeredmény), HG/AG = Home/Away Goals (gólok), R = Result (kimenetel), S/ST = Shots / on Target (lövések), C = Corners (szöglet), F = Fouls (szabálytalanság), Y/R = Yellow/Red.


volt szükséges.

Az eljárás eredményeként egy tiszta, konzisztens, 3800 rekordot és 26 változót tartalmazó adathalmazt kaptam, ami megbízható alapot biztosított a további elemzésekhez. Az egyesített és tisztított adatbázist külön CSV fájlba is exportáltam (`E0_osszesített.csv`), biztosítva a munka reprodukálhatóságát.

2.2 Feltáró Adatelemzés (EDA)

A tisztított adatokon EDA-t végeztem, megvizsgálva a numerikus változók leíró statisztikáit, eloszlását és korrelációs kapcsolatait. Az elemzés eredményei megerősítették a labdarúgásra jellemző ismert mintázatokat, például a gólok Poisson-jellegű eloszlását és a hazai pálya előnyét.

A korrelációs hőtérkép (1. ábra) elemzése során megállapítottam, hogy a kaput eltaláló lövések (HST) szignifikánsan erősebb korrelációt mutatnak a szerzett gólokkal (FTHG) (**0.60**), mint a teljes lövésszám (HS) (**0.33**), ami a lövések minőségének (és nem a mennyiségének) elsődleges fontosságát támasztja alá. Emellett a fogadóirodai oddsok és a gólok között erős negatív korreláció (**-0.29**) figyelhető meg: minél alacsonyabb a hazai odds (azaz minél esélyesebb a csapat), annál több gólt szerez.



1. ábra: Korrelációs Hőtérkép (Főbb változók)


2.3 Hipotézisvizsgálatok

Az EDA során három előzetes hipotézist (H1-H3) fogalmaztam meg, melyeket ebben az alfejezetben statisztikai és gépi tanulási módszerekkel vizsgáltam. Az EDA későbbi fázisában és a feature engineering során további két hipotézist (H4-H5) állítottam fel, melyek bemutatására a 2.4-es, tesztelésére pedig a 2.6-os alfejezetben kerül sor.

2.3.1 A COVID-19 hatása a hazai pálya előnyére (H1)

Feltételeztem (H1), hogy a 2020/2021-es zárt kapus COVID-szezonban szignifikánsan csökkent a hazai győzelmek aránya. Ennek vizsgálatára kiszámítottam a hazai győzelmek szezononkénti százalékos arányát, és az eredményt oszlopdiagramon ábrázoltam, feltüntetve a vizsgált időszak átlagát is.

H1: Hazai győzelmek aránya szezononként (Figyeljük a 2021-es COVID évet!)



2. ábra: H1: Hazai győzelmek aránya szezononként

A 2. ábrán jól látható, hogy a 2021-es szezonban a hazai győzelmek aránya drasztikusan, a vizsgált időszak **44.5%-os** átlaga alá, **39.5%-ra** esett vissza. Ez az eredmény egyértelműen alátámasztja a hipotézist. A hipotézis formális, logisztikus regressziós modellel történő számszerű validálását a 2.6.1-es alfejezetben mutatom be.

2.3.2 A lövések minőségének és mennyiségének prediktív értéke (H2)

A második hipotézisem (H2) szerint a kaput eltaláló lövések (HST) jobb prediktorai a lőtt góloknak (FTHG), mint az összes lövés száma (HS). Ennek megalapozottsága már a korrelációs hőtérképen (1. ábra, lásd 2.2-es alfejezet) is látható volt: a kaput eltaláló lövések (HST) és a lőtt gólok (FTHG) közötti korreláció (0.60) jelentősen magasabb, mint az összes lövésszám (HS) és a gólok közötti korreláció (0.33). A hipotézis formális, regressziós modellel történő számszerű validálását a 2.6.2-es alfejezetben mutatom be.

2.3.3 A fogadóirodai oddsok prediktív ereje (H3)

A harmadik hipotézisem (H3) szerint a fogadóirodai szorzók önmagukban is erős prediktorok. A korrelációs hőtérkép (1. ábra, lásd 2.2-es alfejezet) vizuálisan is alátámasztja ezt a feltételezést: a B365H és az FTHG között erős negatív korreláció (-0.29) figyelhető meg, ami azt jelzi, hogy minél alacsonyabb a hazai odds (minél esélyesebb a csapat), annál több gólt szerez. Ennek a prediktív erőnek a tesztelését és a döntetlenek előrejelzési problémáját egy többosztályos logisztikus regressziós modellel vizsgálom a 2.6.3-as alfejezetben.

2.4 Jellemzőkinyerés (Feature Engineering)

Az EDA eredményeire támaszkodva új, származtatott változókat hoztam létre a prediktív modellek teljesítményének javítása érdekében. A feature engineering fázis központi eleme a csapatok rövid távú teljesítményét, azaz "formáját" leíró mutatók kiszámítása volt. Ez a megközelítés összhangban van a szakirodalomban publikált eredményekkel [2][4], melyek szerint a formaalapú jellemzők jelentősen javítják a predikció pontosságát.

A feladat megoldására implementáltam egy `get_team_form` Python függvényt. Ez iteratívan kigyűjti a csapat referencia dátum előtti utolsó `n_games` (alapértelmezetten 5) mérkőzését, és kiszámítja a szerzett pontokat (győzelem=3, döntetlen=1, vereség=0), valamint az átlagosan lőtt és kapott gólokat. A függvényt minden mérkőzésre mindkét csapatnál


lefuttattam, az 5 meccses múlttal nem rendelkező 119 rekordot pedig a `dropna()` módszerrel eltávolítottam.

Az így létrehozott legfontosabb prediktív változók a következők:

- `Home_Form_Pts_5 / Away_Form_Pts_5`: A csapat által az utolsó 5 mérkőzésen szerzett pontok száma (max. 15).
- `Home_Avg_Scored_5 / Away_Avg_Scored_5`: A csapat által az utolsó 5 mérkőzésen lőtt gólok átlaga.
- `Form_Diff`: A `Home_Form_Pts_5` és `Away_Form_Pts_5` különbsége, mely egyetlen, -15 és +15 közötti skálán mozgó változóban foglalja össze a két csapat aktuális formájának viszonyát. A pozitív érték a hazai csapat jobb formáját, míg a negatív érték a vendég csapat jobb formáját jelzi.

Az új változó prediktív erejét interaktív sűrűség-hisztogramon vizualizáltam.

Forma Különbség eloszlása a végeredmények szerint (Hazai pontok - Vendég)



3. ábra: Forma Különbség eloszlása a végeredmény szerint

A 3. ábrán a három kimeneteli osztály (H, D, A) sűrűségfüggvénye látható a `Form_Diff` függvényében. A hisztogramok egyértelműen mutatják, hogy ez a változó kiválóan szeparálja a kimeneteket: pozitív különbség esetén (jobb hazai forma) a kék H görbe dominál, negatív különbség esetén (jobb vendég forma) a zöld A görbe, míg nulla körüli értékeknél a narancssárga D (döntetlen) görbe a legmagasabb.

A változó prediktív erejét egy egyszerű Random Forest modellel is teszteltem, amely kizárólag a `Form_Diff` alapján **49.4%-os** pontosságot ért el, jelentősen meghaladva a véletlen tippelés **33.3%-os** várható értékét. Ez önmagában igazolja a feature engineering fázis létjogosultságát.

2.5 Új Összefüggések Felfedezése és Új Hipotézisek

Az EDA és a meglévő összefüggések (pl. Piros lapok vs Eredmény, vagy Csapat forma) felmérése után az adatokból olyan mintázatok rajzolódnak ki, amelyek nem annyira triviálisak, mint az induló alap feltevéseim (H1-H3). Ennek megfelelően felállítottam két új, adatvezérelt hipotézist, melyeket a következőkben ismertetek, majd a 2.6-os alfejezetben (Prediktív Modellezés) teszteltem.

2.5.1 H4 Hipotézis: A piros lap aszimmetrikus hatása

A klasszikus felfogás szerint egy hazai pályán játszó csapat masszívabb, így jobban kibír egy emberhátrányt. Azonban az EDA során, a piros lapok hatását vizsgálva azt láttam, hogy a piros lapos esetek drasztikus hatással vannak az eredményre. Feltételezem, hogy a hazai csapat elveszíti dominanciáját emberhátrányban, míg egy vendégcsapat defenzív alapállása miatt kevésbé szenved meg. E hipotézist a 2.6.4-es alfejezetben egy, csak a piros lapokra (HR, AR) épülő logisztikus regressziós modellel tesztelem.

2.5.2 H5 Hipotézis: A Form_Diff prediktív ereje

A 2.4-es alfejezetben (Feature Engineering) létrehozott `Form_Diff` változó a hazai és vendég csapat utolsó 5 mérkőzésen szerzett pontjainak különbségét reprezentálja. Feltételezem, hogy ez a mutató önmagában, oddsok és mérkőzésstatisztikák nélkül is meghaladja a véletlen 33.3%-os pontosságot. E hipotézis tesztelésére a 2.6.5-ös alfejezetben egy Random Forest osztályozót tanítok be, amelynek kizárólagos bemenete a `Form_Diff`.

2.6 Prediktív Modellezés és Hipotézisek Validálása Modellekkel

Az EDA és a Feature Engineering után gépi tanulással teszteltem az eredményeket. Célom volt minden hipotézisre (H1–H5) dedikált modellt építeni, igazolva vagy cáfolva azokat, mielőtt egy végső modellt alkotnék.

2.6.1 Modell a H1 hipotézisre (COVID hatása)

Az első hipotézis (H1) számszerű tesztelésére egy egyszerű logisztikus regressziós modellt építettem. A bemenet egy bináris változó (`Is_Covid_Season`), ami a 2020/2021-es COVID-szezonhoz tartozást jelzi. A célváltozó (`Is_Home_Win`) azt mutatja, hogy a mérkőzés hazai győzelemmel végződött-e. A modellválasztást az indokolta, hogy a logisztikus regresszió együttthatói közvetlenül értelmezhetőek, így a COVID-szezon hatásának iránya és nagysága egyértelműen megállapítható.

A modellben a COVID-szezonra vonatkozó koefficiens negatív előjelű lett (**-0.297**), ami számszerűen is megerősíti, hogy a zárt kapus környezet statisztikailag szignifikánsan csökkentette a hazai csapat győzelmi esélyét. A modell pontossága **46.9%** volt, ami ugyan alacsony, de a feladat itt nem a predikció, hanem a változó hatásának irányának és szignifikanciájának kimutatása volt. Ez az eredmény összhangban van a 2.3.1-es alfejezetben bemutatott vizualizációs elemzéssel (2. ábra).

2.6.2 Modell a H2 hipotézisre (Lövések prediktív értéke)

A második hipotézis (H2) tesztelésére lineáris regressziós modellt építettem, amelynek bemenetei az összes hazai lövés (HS) és a kaput eltaláló hazai lövések (HST) voltak, célváltozója pedig a hazai csapat által szerzett gólok száma (FTHG). A modell együttthatói lehetővé teszik annak számszerű meghatározását, hogy egy-egy további lövés milyen mértékben növeli a várható gólok számát.

Az adatokat 80-20% arányban tanító és teszt halmazra osztottam. A modell az R^2 metrika szerint a variancia **36.5%**-át magyarázta, ami a labdarúgásban rejlő nagyfokú véletlenszerűség mellett elfogadható eredmény. A regressziós együttthatókat megvizsgálva egyértelműen látszik a két változó eltérő fontossága: amíg a kaput eltaláló lövések együttthatója pozitív és jelentős mértékű (**0.355**), addig az összes lövésszám együttthatója gyakorlatilag nulla közeli, sőt enyhén negatív (**-0.037**). Ez a számszerű eredmény igazolja a H2 hipotézist.

2.6.3 Modell a H3 hipotézisre (Oddsok prediktív ereje)

A harmadik hipotézis (H3) szerint a fogadóirodák szorzói önmagukban is erős prediktorai a mérkőzések kimenetelének. Ennek tesztelésére egy többosztályos logisztikus regressziós

modellt építettem, amely kizárólag a Bet365 három oddsát (B365H, B365D, B365A) használta a végeredmény (FTR) predikálására.

A modellt két változatban értékeltem ki: alapértelmezett és kiegyensúlyozott (`class_weight='balanced'`) osztálysúlyozással. A kiegyensúlyozatlan modell **52.9%**-os pontosságot ért el, de ennek háttérében az ún. "accuracy paradox" állt: a modell egyáltalán nem jelzett előre döntetlent (D), mivel a leggyakoribb osztályokra (H és A) fókuszált (a döntetlenekre vonatkozó recall **0.00** volt). A kiegyensúlyozott változat pontossága **48.9%**-ra csökkent, de képes volt mindhárom kimeneteli osztályra érdemi predikciót adni: a döntetlenekre vonatkozó recall **0.43**-ra javult. Ez az elemzés fontos tanulsággal szolgált a végső modell tervezéséhez: a fogadóirodai oddsok valóban kiváló alapot nyújtanak a predikcióhoz, de a döntetlenek előrejelzéséhez elengedhetetlen az osztálykiegyensúlyozás alkalmazása.

2.6.4 Modell a H4 hipotézisre (Piros lapok aszimmetrikus hatása)

A H4 hipotézis tesztelésére logisztikus regressziós modellt építettem, amely kizárólag a hazai (HR) és vendég (AR) piros lapok alapján prediktálja a kimenetelt. A modell pontossága ugyan alacsony (**44.5%**), de a fő cél a változók hatásának számszerűsítése volt. Az együtthatókat megvizsgálva egyértelműen látszik az aszimmetria:

- A hazai piros lap (HR) koefficiense a hazai győzelemre vonatkozóan **-0.474**, ami jelentős negatív hatást jelez.
- A vendég piros lap (AR) koefficiense ugyanerre a kimenetelre vonatkozóan **0.345**, ami pozitív ugyan, de abszolút értékben kisebb, mint a hazai piros lap hatása.

Ez az eredmény számszerűen is igazolja a H4 hipotézist: egy hazai csapat kiállítása statisztikailag nagyobb mértékben rontja a saját győzelmi esélyeit, mint amennyire egy vendégcsapat kiállítása segíti a hazaiak győzelmét.

2.6.5 Modell a H5 hipotézisre (Form_Diff prediktív ereje)

A H5 hipotézis tesztelésére egy Random Forest osztályozót tanítottam be, amelynek kizárólagos bemenete a `Form_Diff` változó volt – tehát sem a fogadóirodai oddsok, sem a mérkőzés közbeni statisztikák nem álltak a modell rendelkezésére. A Random Forest választását az indokolta, hogy ez az algoritmus képes a nem-lineáris összefüggések kezelésére, amelyek a formakülönbség és a mérkőzés kimenetele között fennállhatnak (pl. egy jelentősebb különbségnél a nyerési valószínűség exponenciálisan megnőhet).


A modell a teszt adathalmazon **49.4%**-os pontosságot ért el, ami jelentősen meghaladja a három kimeneteles (H, D, A) véletlen tippelés **33.3%**-os várható értékét. Ez az eredmény igazolja a H5 hipotézist: az általam képzett `Form_Diff` változó önmagában is rendelkezik olyan prediktív erővel, amely lehetővé teszi a véletlen találgatásnál szignifikánsan jobb előrejelzést a mérkőzés kimenetelére vonatkozóan.

2.6.6 A végső, hibrid modell kialakítása és optimalizálása

A projekt záró fázisában egy olyan robusztus modellt alkottam, amely ötvözi a piaci információkat és a saját formamutatókat. Alapként a jól skálázható, nemlineáris összefüggéseket is kezelő `RandomForestClassifier` algoritmust választottam [6]. A modell bemeneteit (X) alapvetően két csoportra osztottam. Az elsőt a fogadóirodai oddsok (B365H, B365D, B365A) adták. A másodikat az általam generált formamutatók: `Home_Form_Pts_5`, `Away_Form_Pts_5`, `Home_Avg_Scored_5`, `Away_Avg_Scored_5` és `Form_Diff`. A célváltozó (y) minden esetben a végeredmény (FTR) volt.


A modell hiperparamétereinek optimalizálásához az Optuna [7] Bayes-féle optimalizáló keretrendszerét használtam. A hangolás a következő tartományokban történt: `n_estimators`

(50-500), max_depth (3-20), min_samples_split (2-20) és min_samples_leaf (1-10). Az optimalizálás célfüggvénye a pontosság (accuracy) volt, 5-rétegű rétegzett keresztvalidációval és class_weight='balanced' osztálykiegyensúlyozással a tanító halmazon. 50 iteráció után a legjobb paraméterekkel (n_estimators=316, max_depth=19, min_samples_split=6, min_samples_leaf=5) felépített modellt a 20%-os teszt adathalmazon értékeltem ki.



4. ábra: Tévesztési Mátrix – Optimalizált Hibrid Modell

A modell a teszt adathalmazon **50.9%**-os pontosságot ért el. A 4. ábrán látható tévesztési mátrix és a klasszifikációs riport tanúsága szerint mindhárom osztályra érdemi predikciót adott: a vendéggyőzelem F1-mutatója **0.56**, a hazai győzelemé **0.59**, míg a legnehezebben prediktálható döntetlené **0.27** volt. Ez utóbbi érték ugyan alacsonynak tűnhet, de jelentős előrelépés ahhoz képest, hogy egy kiegyensúlyozatlan modell a döntetleneket egyáltalán nem prediktálná (0.00-ás recall).



5. ábra: Változók Fontossága az Optimalizált Modellben

A változók fontosságát (feature importance) vizsgálva megállapítható, hogy a legerősebb prediktorok a fogadóirodai szorzók voltak. A három Bet365-odds (különösen a B365A és a B365H) adta a modell döntési súlyának túlnyomó részét. Ugyanakkor az általam generált formamutatók — kiemelten a `Form_Diff` — is érdemi, nullától eltérő fontossággal bírtak, ami azt bizonyítja, hogy a múltbeli teljesítményből származtatott információk a piaci konszenzust kiegészítő prediktív erőt biztosítottak a hibrid modell számára. Ahogy az 5. ábra is mutatja, ez az eredmény összhangban van a szakirodalomban publikált megállapításokkal [2][4], valamint a H5 hipotézis keretében végzett saját elemzésemmel.

2.7 Összefoglalás

A félév során a labdarúgó-mérkőzések kimenetelének prediktálásával foglalkoztam. A kitűzött probléma az volt, hogy a nyilvánosan elérhető mérkőzésstatisztikák és fogadóirodai adatok alapján építhető-e olyan gépi tanulási modell, amely képes a véletlen tippelésnél jobb pontosságú predikcióra.

A probléma megoldása érdekében a football-data.co.uk adatbázisát használtam, és a teljes folyamatot — az adatok automatizált letöltésétől a tisztításon, felderítő elemzésen és feature engineering-en át a gépi tanulási modell optimalizálásáig — a Python programozási nyelv és adatelemzési könyvtárai segítségével, önállóan implementáltam. A munka során öt hipotézist fogalmaztam meg és teszteltem, melyek közül a dedikált modellekkel végzett vizsgálatok a következő főbb megállapításokhoz vezettek:

- A COVID-19 világjárvány miatti zárt kapus környezet statisztikailag szignifikánsan csökkentette a hazai pálya előnyét (H1).
- A kaput eltaláló lövések (HST) szignifikánsan jobb prediktorai a szerzett góloknak, mint a teljes lövésszám (HS) (H2).
- A fogadóirodai oddsok önmagukban is erős prediktorok, de a döntetlenek előrejelzéséhez osztálykiegyensúlyozás szükséges (H3).
- A piros lapok hatása aszimmetrikus: egy hazai kiállítás nagyobb mértékben csökkenti a hazai győzelem esélyét, mint amennyire egy vendég kiállítás növeli azt (H4).
- Az általam képzett `Form_Diff` változó önmagában, a piaci oddsok nélkül is képes a véletlen tippelést szignifikánsan meghaladó predikcióra (H5).

A félév legfontosabb eredménye egy optimalizált, Random Forest alapú hibrid modell, amely a piaci oddsokat és az általam képzett formamutatókat (pl. `Form_Diff`) együttesen használva **50.9%**-os pontosságot ért el a teszt adathalmazon, mindhárom kimeneteli osztályra érdemi predikciót adva.

A munka további lehetséges irányai közé tartozik a modell általánosítása más európai bajnokságokra, a modernebb boosting alapú algoritmusok (pl. XGBoost, LightGBM) teljesítményének összehasonlító vizsgálata, valamint további, külső forrásból származó prediktorok (pl. várható gólok - xG, játékosok piaci értéke, sérülési adatok) integrálása a keretrendszerbe. Ezen túlmenően, a döntetlenek predikciójának további javítása érdekében érdemes lehet megfontolni a probléma kétlépcsős modellezését (először a döntetlen/nem döntetlen bináris osztályozás, majd a győztes predikciója).

3. Irodalom, és csatlakozó dokumentumok jegyzéke

A tanulmányozott irodalom jegyzéke:

- [1] C. Anderson and D. Sally, *The Numbers Game: Why Everything You Know About Football is Wrong*. Penguin Books, 2014.
- [2] R. Baboota and H. Kaur, "Predictive analysis and modelling football results using machine learning approach for English Premier League," *International Journal of Forecasting*, vol. 35, no. 2, pp. 741-755, 2019.
- [3] A. C. Constantinou and N. E. Fenton, "Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries," *Journal of Quantitative Analysis in Sports*, vol. 9, no. 1, pp. 37-50, 2013.
- [4] N. Tax and Y. Joulstra, "Predicting the Dutch football competition using public data: A machine learning approach," *Transactions on Knowledge and Data Engineering*, vol. 10, no. 10, pp. 1-13, 2015.
- [5] [Football-Data.co.uk](https://www.football-data.co.uk), "Downloadable Data Files for Football Betting," [Online]. Available: <https://www.football-data.co.uk/>. [Accessed: 2026-05-10].
- [6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [7] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631.

Csatlakozó egyéb elkészült dokumentációk / fájlok / stb. jegyzéke:

A félév során elvégzett teljes munka egy Jupyter Notebook fájlban (`foci_onlab.ipynb`) került dokumentálásra. A notebook tartalmazza az összes Python forráskódot, az adatelemzés lépéseit, a vizualizációkat és a modellezési eredményeket. A notebook reprodukálható módon, celláról cellára futtatva bemutatja az adatletöltéstől a végső modell kiértékeléséig tartó folyamatot.

A letöltött és tisztított adatbázis a `data/E0_osszesített.csv` fájlban található, amely a notebook 4. fejezetének futtatásával automatikusan előáll.