



ÖNÁLLÓ LABORATÓRIUM

2025/26 2. félév

BME Távközlési és MI Tanszék

Angol Premier League Mérkőzések Elemzése és Prediktív Modellezése

Sportanalitika és Gépi Tanulás a Labdarúgásban

Németh Máté

E3YAXE | Mérnökinformatikus BSc

Konzulens

Frankó Attila

franko@tmit.bme.hu



01

Bevezetés

Problémafelvetés, kutatási célkitűzések és a projekt áttekintése

02

Adatok & Módszertan

Adatgyűjtés, tisztítás, feltáró elemzés és statisztikai módszerek

03

Hipotézisek & Eredmények

Öt hipotézis felállítása, tesztelése és validálása adatokkal

04

Prediktív Modell

Hibrid modell építése, optimalizálás és végső konklúzió



01

Bevezetés

Problémafelvetés és célkitűzések





BEVEZETÉS

A Probléma és a Célkitűzések

⚠ Problémafelvetés

A modern labdarúgásban **óriási szerepe van az adatalapú döntéshozatalnak**. Egy mérkőzés kimenetele látszólag a véletlen is múlhat, de a rendelkezésre álló nyers, sokrétű meccsstatistikából (lövések, szögletek, sárga lapok, fogadóirodai oddsok) **képesek vagyunk-e hasznos következtetéseket és megbízható predikciókat levonni** a mérkőzések végkimenetelére vonatkozóan?

🎯 Fő Célkitűzés

Olyan **gépi tanulási modell építése**, amely a historikus adatok és származtatott jellemzők alapján képes prediktálni a mérkőzések végeredményét (**Hazai győzelem, Döntetlen, Vendég győzelem**), meghaladva a véletlen tippelés 33.3%-os pontosságát.

☰ 5 Részcél

1 **Adatbázis építés**
10 szezon CSV adatainak integrálása

2 **Leíró elemzés**
Trendek feltárása 10 évre visszamenőleg

3 **Feature Engineering**
Új prediktív változók generálása

4 **Hipotézis validálás**
5 hipotézis statisztikai tesztelése

5 **Prediktív modellezés**
Random Forest modell optimalizálása



02

Adatok & Módszertan

Adatgyűjtés, tisztítás és feltáró elemzés



ADATOK & MÓDSZERTAN

Adathalmaz és Adattisztítás



10

Szezon

2015/16 - 2024/25



3800

Mérkőzés

Angol Premier League



155

Változó

Nyers adatokban



Adattisztítási Folyamat



Duplikátumok ellenőrzése

Nem találtunk ismétlődő sorokat az adathalmazban



Hiányzó értékek kezelése

120 oszlopban >90% hiány → irreleváns oszlopok eldobása



Releváns változók kiválasztása

26 oszlop megtartása: gólok, lövések, szögletek, lapok, oddsok



Dátum formázás és rendezés

Egységes datetime formátum, időrendbe rendezés



Végső Adathalmaz

3800

Rekord

26

Változó

- **Alapadatok:** Dátum, Csapatok, Bíró
- **Eredmények:** Gólok, Félidei eredmény
- **Statisztikák:** Lövések, Szögletek, Lapok
- **Oddsok:** Bet365 (H, D, A)



100% Kitöltöttség



Feltáró Adatelemzés (EDA)

Gólok Eloszlása

A gólok **Poisson-jellegű eloszlást** követnek, ami a labdarúgás egyik alaptörvénye. A hazai csapatok átlagosan **1.55 gólt**, a vendégek **1.28 gólt** szereznek mérkőzésenként.

Hazai átlag

1.55

Vendég átlag

1.28

Hazai Pálya Előnye

A vizsgált 10 szezonban a hazai csapatok **45.5%-ban nyertek**, ami erősen alátámasztja a hazai pálya előnyét. A döntetlenek aránya 25.3%, a vendég győzelmeké 29.2%.

45.5%

H

25.3%

D

29.2%

A



Korrelációs Hőtérkép

A kaput eltaláló lövések (HST) **0.60-as korrelációt** mutatnak a gólokkal, míg az összes lövés (HS) csak 0.33-at.

HST - Gól

0.60

HS - Gól

0.33

Fő Tanulságok

1

A lövések minősége fontosabb, mint a mennyisége - a kaput eltaláló lövések sokkal jobban prediktálják a gólokat

2

A fogadóirodai oddsok erős prediktorok - a B365H és FTHG között - 0.29-es negatív korreláció van

3

A hazai pálya előnye stabil - 10 szezon alatt következetesen 45% körül alakul



03

Hipotézisek & Eredmények

Öt hipotézis felállítása és validálása



H1-H3 Hipotézisek Eredményei

H1

IGAZOLVA

COVID-19 Hatása

A 2020/21-es zárt kapus szezonban a hazai győzelmek aránya **drasztikusan csökkent** a nézők hiánya miatt.

Átlag (9 szezon) **44.5%**

2020/21 (COVID) **39.5%**

H2

IGAZOLVA

Lövések Minősége

A kaput eltaláló lövések (HST) **szignifikánsan jobban korrelálnak** a gólokkal, mint az összes lövés.

HST - Gól **0.60**

HS - Gól **0.33**

H3

IGAZOLVA

Oddsok Prediktív Ereje

A fogadóirodai szorzók **erős prediktorok**, de a döntetlenek előrejelzéséhez **osztálykiegyensúlyozás szükséges**.

Kiegyensúlyozatlan modell

52.9%

Döntetlen recall: 0.00

Kiegyensúlyozott modell

48.9%

Döntetlen recall: 0.43

H1-H3 Összefoglalás



Mindhárom hipotézist **sikeresen igazoltam**. A COVID csökkentette a hazai előnyt, a lövések minősége fontosabb a mennyiségnél, és az oddsok valóban erős prediktorok - de a döntetlenek kezelése külön figyelmet igényel.





H4-H5 Hipotézisek és Feature Engineering

H4

IGAZOLVA

Piros Lap Aszimmetrikus Hatása

Egy hazai kiállítás **nagyobb mértékben csökkenti** a hazai győzelem esélyét, mint amennyire egy vendég kiállítás növeli azt.

Hazai piros lap

-0.474

negatív hatás

Vendég piros lap

+0.345

pozitív hatás



Feature Engineering

A csapatok **5 mérkőzéses formájának** számítása: szerzett pontok, átlagosan lőtt és kapott gólok.



Home_Form_Pts_5 / Away_Form_Pts_5

Utolsó 5 meccs pontjai (max. 15)



Home_Avg_Scored_5 / Away_Avg_Scored_5

Átlagosan lőtt gólok



Form_Diff

Hazai és vendég forma különbsége (-15 és +15)

H5

IGAZOLVA

Form_Diff Prediktív Ereje

Az általam képzett **Form_Diff változó önmagában** is képes a véletlen tippelést szignifikánsan meghaladó predikcióra.

Véletlen tippelés

33.3%

Form_Diff modell

49.4%

↑ +16.1% javulás



Tanulságok

1


A hazai csapat jobban szenved az emberhátránytól – elveszti dominanciáját

2

A forma különbség önmagában is erős prediktor – a piaci adatok nélkül is 49.4%

3

A feature engineering létjogosultsága bizonyított – saját változók jelentős prediktív erővel



04

Prediktív Modell

Hibrid modell és végső eredmények



PREDIKTÍV MODELL

A Végő Hibrid Modell és Konklúzió



Modell Architektúra

Random Forest Classifier – piaci oddsok és saját formamutatók kombinációja. Optimalizálás Optuna Bayes-féle keretrendszerrel.

📈 Piaci Adatok

- B365H (Hazai odds)
- B365D (Döntetlen odds)
- B365A (Vendég odds)

📊 Saját Mutatók

- Home_Form_Pts_5
- Away_Form_Pts_5
- Form_Diff



Végő Pontosság

50.9%

Hazai F1

0.59

Döntetlen F1

0.27

Vendég F1

0.56



Optimalizált Hiperparaméterek

n_estimators

316

max_depth

19

min_samples_split

6

min_samples_leaf

5



Változók Fontossága

B365A (Vendég odds)

35%

B365H (Hazai odds)

28%

Form_Diff

15%

B365D (Döntetlen odds)

12%



50 iteráció, 5-rétegű keresztvalidáció, class_weight='balanced'



12 / 15



ÖSSZEFOGLALÁS

A Projekt Eredményei

● **50.9%**

Végső modell pontossága

+17.6%-kal haladja meg a véletlen tippelést (33.3%)

● **5 / 5**

Igazolt hipotézis


Minden hipotézis statisztikailag igazolódott

● **3800**

Elemzett mérkőzés (10 szezon)

26 prediktív változóval, 100%-os kitöltöttséggel

Modell Teljesítmény - F1 Értékek



Kulcs Tanulságok

- A **fogadóirodai oddsok** a legerősebb prediktorok – a vendég odds 35%, a hazai odds 28% fontossággal szerepel a modellben
- A **feature engineering** létjogultsága bizonyított – a Form_Diff változó 15% fontossággal és 49.4% önálló pontossággal rendelkezik
- A **döntetlenek előrejelzése** továbbra is kihívás – 0.27 F1-értékkel a modell leggyengébb pontja, ez a további fejlesztés fókuszpontja
- A **hazai pálya előnye** stabil tényező – 45.5% hazai győzelmi arány, amely a COVID alatt is szignifikánsan csökkent nézők nélkül
- A **hibrid modell** – piaci adatok és saját mutatók kombinációja – hatékonyabb, mint bármelyik önmagában



TOVÁBBFEJLESZTÉSI LEHETŐSÉGEK

Jövőbeli Kutatási Irányok

1

Döntetlen Predikció Javítása

Külön **bináris döntetlen-detektor** modell építése, osztály-súlyozás finomhangolása, vagy ensemble módszerek alkalmazása a döntetlenek jobb előrejelzésére. Jelenleg ez a modell leggyengébb pontja 0.27 F1-értékkel.



Prioritás: Magas

2

Mélytanulási Modellek

Neurális hálók, LSTM-ek vagy Transformer-alapú modellek kipróbálása, amelyek képesek az időbeli sorozatok mintázatainak modellezésére és a mérkőzések közötti összefüggések feltárására.



Prioritás: Magas

3

Adathalmaz Bővítése

További **európai bajnokságok** bevonása (La Liga, Serie A, Bundesliga), játékos-szintű statisztikák integrálása, valamint szezonon belüli időbeli változások figyelembe vétele a modell pontosságának növelése érdekében.



Prioritás: Közepes

4

Valós Idejű Validálás

A modell **élő mérkőzések adatain** történő tesztelése, folyamatos visszacsatolási loop kialakítása, és a modell teljesítményének nyomon követése idővel a valós prediktív képességének felmérésére.



Prioritás: Közepes

5

Modell Magyarázhatósága

SHAP értékek és más interpretálhatósági technikák alkalmazása a modell döntéseinek jobb megértésére, valamint a predikciók mögötti logika transzparens bemutatása a felhasználók számára.



Prioritás: Alacsony

6

Új Feature Változók

További **külső adatforrások** integrálása: sérülési listák, időjárási adatok, utazási távolságok, pihenőnapok száma és a mérkőzés időpontja a prediktív teljesítmény növeléséhez.



Prioritás: Közepes



Köszönöm a figyelmet!

Önálló Laboratórium | 2025/26 2. félév

Hallgató

Németh Máté

E3YAXE | Mérnökinformatikus BSc

nemmatee2004@gmail.com

Konzulens

Frankó Attila

Távközlési és MI Tanszék

franko@tmit.bme.hu



nemmatee2004@gmail.com



BME Távközlési és MI Tanszék



15 / 15